







스마트인재개발원
Smart Human Resources Development

정 봉 군 연구원



분류(Classification) vs 회귀(Regression)

분류



결과값

**범주값
(이산값)**

회귀



**숫자값
(연속값)**

분류(Classification)

- 데이터가 주어졌을 때 어느 범주에 속한 데이터인지 판단하고 예측



회귀(Regression)

- 오랜 기간동안 현대 통계학에서 발생되어 다양하게 이용되는 학문분야
- 연속적인 실수 값을 예측 하는 분야



"내일은 얼마나 팔릴까?" 외식 수요예측 고민 AI로 해결한다


일별 대표메뉴 수요예측

날짜	구분	합계	동양궁	팻타이궁	태국국밥	나시고령 복음밥	새우게살볶음밥	뿌꿏콩커리라이스
어제	실제매출	78	9	32	0	12	2	23
오늘	예측매출	67	12	31	0	9	0	15
내일	예측매출	77	12	35	0	10	0	20



- 팻타이궁
- 뿌꿏콩커리라이스
- 동양궁
- 나시고령 복음밥
- 태국국밥
- 새우게살볶음밥

순위	메뉴명	어제 실제매출	오늘 예측매출	지난주 같은 요일 대비
	판매수량 합계	78	67	▼-32%
1	팻타이궁	32	31	▼-12%
2	뿌꿏콩커리라이스	23	15	▼-12%
3	동양궁	9	12	▼-12%
4	나시고령 복음밥	12	9	▼-12%
5	태국국밥	0	0	▼-12%
6	새우게살볶음밥	2	0	▼-12%



1

선형회귀 모델을 이해할 수 있다.

2

회귀 모델의 개념을 바탕으로
선형회귀 모델을 사용할 수 있다.

Linear Regression 선형 회귀

학생들의 시험 성적이 []에 따라 다 다르다



공부한 시간, 시험 당일의 컨디션, 사교육비 지출액...

Linear Regression

선형 회귀

학생들의 시험 성적이 [공부시간]에 따라 다 다르다

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

7시간 공부하면?




Linear Regression 선형 회귀

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

$$y = ax + b$$

$$y = 10x + 0$$




Linear Regression 선형 회귀

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

Training Data

$$y = 10x + 0$$




공부 시간(x)	시험 성적(y)
7	70
5	50
3	30

Linear Regression



선형 회귀

- 독립변수(X)와 종속변수(Y)와의 **선형 관계**를 학습하여 모델링하는 방법
- **선형 함수**를 통해 미지의 데이터에 대해 **예측**을 수행
- 종속변수(Y)가 연속형일 경우 수치 예측, 범주형일 경우 분류로 사용 가능



공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

$$y = ax + b$$



Linear Model - Regression



Linear Model - Regression



Linear Model – Residual Sum of Square



$$\hat{y} = wx + b$$

손실함수 : 알고리즘이 예측한 값과 실제 값의 차이를 비교하기 위한 함수


$$RSS(w, b) = \sum (y - \hat{y})^2$$

RSS(Residual Sum of Square, 잔차제곱합)

예측을 잘 수행할 수 있는
 w 와 b 를 찾는 것

$\equiv$

손실 함수 값이 가장 최소가 되는
 w 와 b 를 찾는 것




$$\hat{y} = wx + b$$

- 목적
 - 손실 함수 값이 가장 최소화 되는 w 와 b 를 찾는 것



- ① OLS(Ordinary Least Square, 최소제곱법)
- ② GD(Gradient Descent, 경사하강법)



Linear Model - Residual Sum of Square

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법
- ① OLS(Ordinary Least Square, 최소제곱법)
 - ② GD(Gradient Descent, 경사하강법)

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

① OLS(Ordinary Least Square, 최소제곱법)

$$w = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2}$$

$$b = \frac{(\sum y) - w(\sum x)}{n} = \bar{y} - w\bar{x}$$

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

$$\hat{y} = wx + b$$

$$w = \frac{4(1650) - (23)(230)}{4(165) - (23)^2}$$

$$w = \frac{6600 - 5290}{660 - 529} = \frac{1310}{131}$$

$$w = 10$$

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

① OLS(Ordinary Least Square, 최소제곱법)

$$w = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2}$$

$$b = \frac{(\sum y) - w(\sum x)}{n} = \bar{y} - w\bar{x}$$

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

$$\hat{y} = 10x + b$$

$$b = \frac{(230) - 10(23)}{4}$$

$$b = \frac{230 - 230}{4}$$

$$b = 0$$

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

① OLS(Ordinary Least Square, 최소제곱법)

$$w = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2}$$

$$b = \frac{(\sum y) - w(\sum x)}{n} = \bar{y} - w\bar{x}$$

공부 시간(x)	시험 성적(y)
9	90
8	80
4	40
2	20

$$\hat{y} = 10x + b$$

$$b = 57.5 - 10(5.75)$$

$$b = 0$$

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

① OLS(Ordinary Least Square, 최소제곱법)

- 계산이 빠르고, 수학적으로 정확한 해(w, b)를 찾음
- 데이터가 선형 관계를 따르고, 많지 않을 때에는 유용
- 규모가 큰 데이터 셋에 대해서는 계산 복잡도가 높아지기 때문에 메모리 문제가 발생
- 수식을 이용한 해석적 방법이기에, 해(w, b)는 변함없이 산출 됨

Linear Model

선형 모델


① OLS(Ordinary Least Square, 최소제곱법)

LinearRegression()

- 주요 속성

.intercept_ # bias(절편, 편향) 확인

.coef_ # w(weight, 가중치) 확인



Linear Model – LinearRegression() 실습

**LinearRegression() 모델을 활용해
보스턴 집값 데이터를 이용하여
주택 가격을 예측 해보자.**


- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)



평균제곱오차 (MSE, Mean Squared Error)


$$= \frac{1}{N} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$



~~$w_{(new)} - w_{(old)}$ - 기울기~~

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)



~~$$W_{(new)} = W_{(old)} + \text{기울기}$$~~


$$W_{(new)} = W_{(old)} - \alpha * \text{기울기}$$

$$w := w - \alpha \frac{\partial MSE(w, b)}{\partial w}$$

학습률(learning rate) : 기울기의 보폭


- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)




평균제곱오차 (MSE, Mean Squared Error)

$$= \frac{1}{N} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)



평균제곱오차 (MSE, Mean Squared Error)


$$= \frac{1}{N} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$




$$w := w - \alpha \frac{\partial MSE(w, b)}{\partial w}$$

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)



$$\text{평균제곱오차 (MSE, Mean Squared Error)} = \frac{1}{N} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$




$$w := w - \alpha \frac{\partial MSE(w, b)}{\partial w}$$

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

1) 파라미터 초기화 : w 와 b 를 임의의 값으로 초기화

- 운이 아주 좋으면 최적의 w 값을 단번에 찾겠지만, 그렇지 않을 확률이 훨씬 더 높음
- 대부분의 경우는 최적의 w 값과 거리가 멀



Linear Model - Gradient Descent

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

- 1) 파라미터 초기화 : w 와 b 를 임의의 값으로 초기화
- 2) 예측 : $\hat{y} = wx + b$, 현재의 w 와 b 를 사용하여 y 를 예측

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

- 1) 파라미터 초기화 : w 와 b 를 임의의 값으로 초기화
- 2) 예측 : $\hat{y} = wx + b$, 현재의 w 와 b 를 사용하여 y 를 예측
- 3) 오차계산 : 예측 값과 실제 값 사이의 오차를 계산
 - Loss Function(손실함수) 사용_주로 MSE(평균제곱오차) 활용

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)



- 1) 파라미터 초기화 : w 와 b 를 임의의 값으로 초기화
- 2) 예측 : $\hat{y} = wx + b$, 현재의 w 와 b 를 사용하여 y 를 예측
- 3) 오차계산 : 예측 값과 실제 값 사이의 오차를 계산
- 4) 기울기 계산 : Loss 값이 낮아지는 방향을 찾기 위해 Loss값의 기울기 값을 계산
- Loss값(손실 함수 값)을 w 에 대해서 편미분($\partial MSE(w, b) / \partial w$)

- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

- α (학습률, learning rate) : 기울기의 보폭



$$w := w - \alpha \frac{\partial MSE(w, b)}{\partial w}$$



- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

- α (학습률, learning rate) : 기울기의 보폭




- 손실 함수 값이 가장 최소가 되는 w 와 b 를 찾는 방법

② GD(Gradient Descent, 경사하강법)

- 1) 파라미터 초기화 : w 와 b 를 임의의 값으로 초기화
- 2) 예측 : $\hat{y} = wx + b$, 현재의 w 와 b 를 사용하여 y 를 예측
- 3) 오차계산 : 예측 값과 실제 값 사이의 오차를 계산
- 4) 기울기 계산 : Loss 값이 낮아지는 방향을 찾기 위해 Loss값의 기울기 값을 계산
- 5) 파라미터 업데이트 : 기울기와 학습률을 사용하여 파라미터(w, b)를 업데이트

$$w := w - \alpha \frac{\partial MSE(w, b)}{\partial w}$$

α (학습률, learning rate) : 기울기의 보폭



Linear Model

선형 모델

① 단순 선형회귀(Simple Linear Regression)

$$\hat{y} = wx + b$$





Linear Model

선형 모델

② 다중 선형회귀(Multiple Linear Regression)

$$\hat{y} = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5 + b$$



$$\hat{y} = w_1x_1 + w_2x_2 + b$$

**시각화가 힘들
수식으로만 표현 가능**

$$\hat{y} = w_1x_1 + w_2x_2 + \cdots w_ix_i + b$$

Linear Model

선형 모델

② GD(Gradient Descent, 경사하강법)


SGDRegressor()

- 주요 속성

`.intercept_` # bias(절편, 편향) 확인
`.coef_` # w(weight, 가중치) 확인

- 주요 하이퍼 파라미터

`loss = 'squared loss',` # 손실 함수 지정('squared loss' == MSE)
`max_iter = 100,` # 최대 반복 횟수
`eta0 = 0.1,` # 초기 학습률
`learning_rate = 'constant'` # 학습률 스케줄링 방법('constant' == eta0 고정값으로 사용)



Linear Model – SGDRegressor() 실습

**SGDRegressor() 모델을 활용해
보스턴 집값 데이터를 이용하여
주택 가격을 예측 해보자.**

Linear Model 선형 모델

LinearRegression()

SGDRegressor()

장점

**간단하고 효과적
해석력**





**대규모 데이터에서 빠르게 학습
온라인 학습(점진적 학습) 가능**

단점


**대규모 데이터 셋에 대한 계산 비용이 높음
과적합을 피하기 어려움**

하이퍼 파라미터 튜닝 필요

Linear Model 선형 모델




Linear Model 선형 모델




$$y = x$$

Linear Model 선형 모델




$$y = x^1$$

Linear Model 선형 모델



$$y = x^2$$

Linear Model 선형 모델




$$y = x^3$$

Linear Model

선형 모델

① 단순 선형회귀(Simple Linear Regression)

$$h_w(x) = w_1 x^1 + b$$




x (주택의 면적)	y (주택 임대료)
10	1
20	3
30	5
25	3.5
15	1
...	...

Linear Model 선형 모델

② 다항 회귀(Polynomial Regression)

2차식

$$h_w(x) = w_1x^1 + w_2x^2 + b$$




x (주택의 면적)	주택의 면적 ²	y (주택 임대료)
10	100	1
20	400	3
30	900	5
25	625	3.5
15	225	1
...	...	...

Linear Model 선형 모델

② 다항 회귀(Polynomial Regression)

3차식

$$h_w(x) = w_1x^1 + w_2x^2 + w_3x^3 + b$$



x (주택의 면적)	주택의 면적 2	주택의 면적 3	y (주택 임대료)
10	100	1000	1
20	400	8000	3
30	900	27000	5
25	625	15625	3.5
15	225	3375	1
...	...	...	...

Linear Model

선형 모델

② 다항 회귀(Polynomial Regression)

1차


2차

3차

4차



정확도 증가, 과적합 가능성



정확도 감소, 해석 용이

**PolynomialFeatures() 다항변형기를 활용해
보스턴 집값 데이터를 이용하여
주택 가격을 예측 해보자.**